

AirQuality

March 20, 2025

1 Calidad de Aire en CDMX usando datos de RAMA

Autor: Thanos Drossos

Clase: Análisis Exploratorio de Datos

1.1 Tarea

1. ESCOGER AL MENOS TRES ESTACIONES DE MONITOREO, QUE REGISTREN O3, CO Y NO2.

Estaciones (claves): BJU, UAX, MER

2. REGISTRAR EL PROMEDIO DIARIO DE CADA CONTAMINANTE POR UN PERIODO CONTINUO DE AL MENOS TRES AÑOS.

Periodo: 2020-2024

3. OBTENER EL HISTOGRAMA DE CONCENTRACIÓN DE CADA CONTAMINANTE, POR ESTACIÓN.
4. COMPUTAR LA MATRIZ DE CORRELACIÓN PARA CADA CONTAMINANTE, UTILIZANDO:
 - COEFICIENTE DE PEARSON
 - COEFICIENTE DE SPEARMAN
 - FUNCIÓN DE INFORMACIÓN MUTUA Para cada par de estaciones.
5. ¿QUÉ PREGUNTAS SE PUEDEN FORMULAR SOBRE ESTE FENÓMENO A PARTIR DE ESTE CONJUNTO DE DATOS?

1.2 Procesamiento de Datos

Este código realiza un análisis exploratorio de datos de calidad del aire en la Ciudad de México. En particular:

1. Importa las librerías necesarias para el análisis (pandas, numpy, matplotlib, seaborn)
2. Define los contaminantes a analizar (CO, O3, NO2), el periodo (2020-2024) y las estaciones (BJU, UAX, MER)
3. Lee los archivos Excel de datos para cada contaminante y año
4. Procesa los datos, convirtiendo valores -99 a NaN (datos faltantes) y creando columnas de fecha y hora
5. Calcula promedios diarios de concentración para cada contaminante y estación

6. Genera histogramas para visualizar la distribución de concentraciones
7. Calcula matrices de correlación utilizando:
 - Coeficiente de Pearson (correlación lineal)
 - Coeficiente de Spearman (correlación de rangos)
 - Información Mutua (relaciones no lineales)

Los resultados iniciales muestran los primeros registros de promedios diarios para cada contaminante, permitiendo una primera aproximación a los rangos de valores.

- Las distribuciones de todos los contaminantes están sesgadas hacia la derecha
- Las correlaciones de un contaminante entre las 3 estaciones son altas para CO (>0.7) y muy altas para O₃ y NO (>0.8).

```
[1]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from glob import glob
from scipy.stats import pearsonr, spearmanr
from sklearn.feature_selection import mutual_info_regression

# Define contaminants and years
contaminants = ['CO', 'O3', 'NO2']
years = range(2020, 2025) # 2020-2024
stations = ['BJU', 'UAX', 'MER']

# Dictionary to store processed data
data_by_contaminant = {contaminant: {} for contaminant in contaminants}

# Read all excel files and extract required data
for contaminant in contaminants:
    dfs = []
    for year in years:
        filename = f"{year}-{contaminant}.xls"
        if os.path.exists(filename):
            print(f"Processing {filename}")
            try:
                # Read Excel file, adjust format as needed
                df = pd.read_excel(filename)

                # Filter only the required stations
                station_columns = [col for col in df.columns if col in stations]
                if not station_columns:
                    print(f"No required stations found in {filename}")
                    continue

                # Keep only date, time and station columns
```

```

        columns_to_keep = ['FECHA', 'HORA'] + station_columns
        df = df[columns_to_keep]

        # Convert -99 values to NaN (missing data)
        df = df.replace(-99, np.nan)

        # Add year information and append to list
        df['YEAR'] = year
        dfs.append(df)
    except Exception as e:
        print(f"Error processing {filename}: {e}")

if dfs:
    # Combine all data for this contaminant
    combined_df = pd.concat(dfs, ignore_index=True)

    # Create datetime column
    combined_df['DATETIME'] = pd.to_datetime(combined_df['FECHA'],
    ↪format='%d.%m.%Y', errors='coerce')
    combined_df['DATE'] = combined_df['DATETIME'].dt.date

    # Store in dictionary
    data_by_contaminant[contaminant] = combined_df
else:
    print(f"No data found for {contaminant}")

# Calculate daily averages for each station and contaminant
daily_avg_by_contaminant = {}

for contaminant, df in data_by_contaminant.items():
    if not df.empty:
        # Group by date and calculate mean for each station
        daily_avg = df.groupby('DATE')[stations].mean()
        daily_avg_by_contaminant[contaminant] = daily_avg

        print(f"Daily averages for {contaminant}:")
        print(daily_avg.head())

# Create histograms of concentration for each contaminant by station
for contaminant, daily_avg in daily_avg_by_contaminant.items():
    fig, axes = plt.subplots(1, len(stations), figsize=(15, 5))
    fig.suptitle(f'Histograms of {contaminant} Concentration by Station')

    for i, station in enumerate(stations):
        if station in daily_avg.columns:
            axes[i].hist(daily_avg[station].dropna(), bins=30, alpha=0.7)
            axes[i].set_title(f'Station {station}')

```

```

        axes[i].set_xlabel('Concentration')
        axes[i].set_ylabel('Frequency')

plt.tight_layout()
plt.show()

# Compute correlation matrices for each contaminant
correlation_results = {}

for contaminant, daily_avg in daily_avg_by_contaminant.items():
    # Initialize correlation dictionaries
    pearson_corr = pd.DataFrame(index=stations, columns=stations)
    spearman_corr = pd.DataFrame(index=stations, columns=stations)
    mutual_info_corr = pd.DataFrame(index=stations, columns=stations)

    # Calculate correlations for each pair of stations
    for station1 in stations:
        for station2 in stations:
            if station1 in daily_avg.columns and station2 in daily_avg.columns:
                # Get data and replace -99 values with NaN (measurement errors)
                data1 = daily_avg[station1].replace(-99, np.nan)
                data2 = daily_avg[station2].replace(-99, np.nan)

                # Get data without NaN
                valid_mask = ~(data1.isna() | data2.isna())
                data1 = data1[valid_mask].values
                data2 = data2[valid_mask].values

                if len(data1) > 1: # Need at least 2 points for correlation
                    # Pearson correlation
                    pearson, _ = pearsonr(data1, data2)
                    pearson_corr.loc[station1, station2] = pearson

                    # Spearman correlation
                    spearman, _ = spearmanr(data1, data2)
                    spearman_corr.loc[station1, station2] = spearman

                    # Mutual Information
                    mi = mutual_info_regression(data1.reshape(-1, 1), data2)
                    mutual_info_corr.loc[station1, station2] = mi[0]

    correlation_results[contaminant] = {
        'pearson': pearson_corr,
        'spearman': spearman_corr,
        'mutual_info': mutual_info_corr
    }

```

```

# Before plotting, ensure all correlation matrices contain only numeric
↪ values
pearson_corr = pearson_corr.astype(float)
spearman_corr = spearman_corr.astype(float)
mutual_info_corr = mutual_info_corr.astype(float)

# Plot correlation matrices
fig, axes = plt.subplots(1, 3, figsize=(18, 5))
fig.suptitle(f'Correlation Matrices for {contaminant}')

sns.heatmap(pearson_corr, annot=True, cmap='coolwarm', vmin=-1, vmax=1,
↪ ax=axes[0])
axes[0].set_title('Pearson Correlation')

sns.heatmap(spearman_corr, annot=True, cmap='coolwarm', vmin=-1, vmax=1,
↪ ax=axes[1])
axes[1].set_title('Spearman Correlation')

sns.heatmap(mutual_info_corr, annot=True, cmap='viridis', ax=axes[2])
axes[2].set_title('Mutual Information')

plt.tight_layout()
plt.show()

```

Processing 2020C0.xls
 Processing 2021C0.xls
 Processing 2022C0.xls
 Processing 2023C0.xls
 Processing 2024C0.xls
 Processing 202003.xls
 Processing 202103.xls
 Processing 202203.xls
 Processing 202303.xls
 Processing 202403.xls
 Processing 2020N02.xls
 Processing 2021N02.xls
 Processing 2022N02.xls
 Processing 2023N02.xls
 Processing 2024N02.xls
 Daily averages for CO:


	BJU	UAX	MER
DATE			
2020-01-01	0.458333	NaN	0.630435
2020-01-02	0.128571	NaN	0.242857
2020-01-03	0.270833	NaN	0.491667
2020-01-04	0.304167	0.295833	0.454167
2020-01-05	0.520833	0.445833	0.391667

Daily averages for O3:


	BJU	UAX	MER
DATE			
2020-01-01	16.521739	23.652174	18.086957
2020-01-02	16.047619	21.666667	15.285714
2020-01-03	21.375000	27.454545	19.250000
2020-01-04	23.764706	28.750000	21.666667
2020-01-05	NaN	28.541667	24.916667

Daily averages for NO2:


	BJU	UAX	MER
DATE			
2020-01-01	16.086957	9.000000	16.521739
2020-01-02	9.190476	3.904762	12.761905
2020-01-03	22.583333	12.100000	29.541667
2020-01-04	28.833333	NaN	37.791667
2020-01-05	36.166667	NaN	42.166667




Histograms of NO2 Concentration by Station




Correlation Matrices for CO



Correlation Matrices for O3



Correlation Matrices for NO2



1.2.1 1. Como cambia el nivel de contaminacion durante el tiempo en cada estación?

Este análisis muestra cómo cambian los niveles de contaminación a lo largo del tiempo para cada estación y contaminante:

- Crea series temporales de promedios mensuales para cada contaminante (CO, O3, NO2)
- Visualiza la evolución de las concentraciones en las tres estaciones monitoreadas (BJU, UAX, MER)
- Permite identificar tendencias a largo plazo y comparar niveles entre estaciones




Resultados interesantes: - Se observan patrones cíclicos en los niveles de O3, con picos que parecen ocurrir en ciertos periodos del año - El CO muestra niveles relativamente estables con algunas fluctuaciones menores y picos los fines del año - El NO2 presenta diferencias más marcadas entre estaciones, sugiriendo variabilidad espacial importante

```
[2]: # Time series of contaminant levels with monthly averages
for contaminant, df in data_by_contaminant.items():
    if not df.empty:
        # Create a date index for proper time series with explicit index names
        monthly_avg = df.groupby([df['DATETIME'].dt.year, df['DATETIME'].dt.
        ↪month])[stations].mean()
        monthly_avg.index.names = ['Year', 'Month'] # Give explicit names to
        ↪prevent conflicts
        monthly_avg = monthly_avg.reset_index()

        # Create proper date column using the named columns
        monthly_avg['Date'] = pd.to_datetime(monthly_avg['Year'].astype(str) +
        ↪'-' +
        monthly_avg['Month'].astype(str) +
        ↪'-01')

        plt.figure(figsize=(15, 6))
        for station in stations:
            if station in df.columns:
                plt.plot(monthly_avg['Date'], monthly_avg[station], marker='o',
                ↪linestyle='-', label=station)

        plt.title(f'{contaminant} Monthly Average Concentration (2020-2024)')
        plt.xlabel('Date')
        plt.ylabel('Concentration')
        plt.legend()
        plt.grid(True, alpha=0.3)
        plt.tight_layout()
        plt.show()
```

1.2.2 2. Hay patrones estacionales?

Este análisis examina si existen patrones estacionales en los niveles de contaminación:


- Utiliza diagramas de caja (boxplots) para visualizar la distribución de concentraciones por mes
- Agrupa los datos por mes (1-12) para cada estación y contaminante
- Permite identificar si ciertos meses presentan consistentemente mayores o menores niveles de contaminación


Observaciones clave: - El ozono (O3) muestra un claro patrón estacional con niveles más altos durante los meses de primavera (marzo-mayo) - El NO2 y CO muestra algunos patrones estacionales durante los meses de noviembre hasta febrero, posiblemente relacionados con patrones de tráfico o actividad industrial - La variabilidad (tamaño de las cajas) también cambia según la temporada, sugiriendo que algunas épocas tienen concentraciones más estables que otras

```
[3]: # Seasonal patterns (box plots by month)
for contaminant, df in data_by_contaminant.items():
    if not df.empty:
        # Add month column
        df['Month'] = df['DATETIME'].dt.month

        plt.figure(figsize=(15, 6))
        for i, station in enumerate(stations, 1):
            if station in df.columns:
                plt.subplot(1, len(stations), i)
                monthly_data = [df[df['Month'] == m][station].dropna() for m in
                                range(1, 13)]
                plt.boxplot(monthly_data, labels=[f'{m}' for m in range(1, 13)])
                plt.title(f'{contaminant} at {station}')
                plt.xlabel('Month')
                plt.ylabel('Concentration')

        plt.tight_layout()
        plt.show()
```





1.2.3 3. Como se evoluciona la contaminacion promedio en cada estacion durante los 5 años analizados?

Este análisis compara los niveles promedio de contaminación año a año:

- Calcula el promedio anual de cada contaminante para cada estación
- Visualiza la evolución interanual mediante gráficos de barras
- Permite identificar tendencias a largo plazo y comparar entre los años 2020-2024

Resultados destacables: - Se puede observar una tendencia general de empeoramiento de la calidad del aire - Lo único que se mejoró durante los 4 años fueron los niveles de O3 en la estación de la Merced

```
[4]: # Year-over-year comparison
for contaminant, df in data_by_contaminant.items():
```


```

if not df.empty:
    yearly_avg = df.groupby('YEAR')[stations].mean()


    plt.figure(figsize=(12, 6))
    yearly_avg.plot(kind='bar')
    plt.title(f'{contaminant} Yearly Average by Station')
    plt.xlabel('Year')
    plt.ylabel('Average Concentration')
    plt.xticks(rotation=0)
    plt.legend(title='Station')
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()

```


<Figure size 1200x600 with 0 Axes>



<Figure size 1200x600 with 0 Axes>



<Figure size 1200x600 with 0 Axes>



1.2.4 4. Cuales son las horas con las contaminaciones más altas/bajas en cada estación?

Este análisis examina cómo varían los niveles de contaminación a lo largo del día y de la semana:

- Gráficos de línea: muestran el promedio de concentración por hora del día para cada contaminante y estación
- Mapas de calor: visualizan la concentración por hora del día y día de la semana, identificando patrones temporal-semanales

Hallazgos importantes: - Se observan claros patrones diarios en los contaminantes, especialmente:
 - El NO₂ y CO muestra picos durante las horas pico de tráfico y la actividad urbana (mañana a partir de las 5 y tarde después de las 6) - El O₃ tiende a aumentar durante las horas de mayor radiación solar (mediodía-tarde)

- Los mapas de calor revelan diferencias entre días laborables y fines de semana:
 - Los niveles de contaminantes primarios (NO₂, CO) suelen ser más bajos los fines de semana
 - El patrón temporal del O₃ es similar entre días laborables y fines de semana

Estos patrones son consistentes con las fuentes esperadas de contaminación: tráfico vehicular (NO₂, CO) y reacciones fotoquímicas (O₃).

```

[5]: # Daily patterns (by hour of day)
for contaminant, df in data_by_contaminant.items():
    if not df.empty and 'HORA' in df.columns:
        hourly_avg = df.groupby('HORA')[stations].mean()

        plt.figure(figsize=(12, 6))
        hourly_avg.plot()
        plt.title(f'{contaminant} Average Concentration by Hour of Day')
        plt.xlabel('Hour of Day')
        plt.ylabel('Concentration')
        plt.grid(True, alpha=0.3)
        plt.legend(title='Station')
        plt.tight_layout()
        plt.show()


# Weekly patterns (heatmap)
for contaminant, df in data_by_contaminant.items():
    if not df.empty:
        # Add day of week
        df['DayOfWeek'] = df['DATETIME'].dt.dayofweek

        for station in stations:
            if station in df.columns:
                pivot = df.pivot_table(index='HORA', columns='DayOfWeek',
↪ values=station, aggfunc='mean')


                plt.figure(figsize=(10, 8))
                sns.heatmap(pivot, cmap='YlOrRd', annot=False,
↪ cbar_kws={'label': 'Concentration'})
                plt.title(f'{contaminant} at {station}: Hour vs Day of Week')
                plt.xlabel('Day of Week (0=Monday, 6=Sunday)')
                plt.ylabel('Hour of Day')
                plt.tight_layout()
                plt.show()

```


<Figure size 1200x600 with 0 Axes>





<Figure size 1200x600 with 0 Axes>





<Figure size 1200x600 with 0 Axes>


























1.2.5 6. Cuales son las correlaciones de diferentes contaminantes en las 3 estaciones?

Matrices de correlación entre los contaminantes: se observa que existen correlaciones muy altas (>0.8) del mismo contaminante en varias estaciones, y correlaciones altas (0.7-0.8) entre NO₂ y CO en diferentes estaciones. La correlación de O₃ con los demás contaminantes es casi nula.

```
[6]: # Correlation between different contaminants
# Create a combined dataframe with all contaminants
combined_daily = pd.DataFrame()


for contaminant, daily_avg in daily_avg_by_contaminant.items():
    for station in stations:
        if station in daily_avg.columns:
            col_name = f"{contaminant}_{station}"
            combined_daily[col_name] = daily_avg[station]

# Calculate and plot correlation matrix
plt.figure(figsize=(12, 10))
```

```

corr_matrix = combined_daily.corr()
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
sns.heatmap(corr_matrix, annot=True, mask=mask, cmap='coolwarm', vmin=-1, v
    ↪vmax=1)
plt.title('Correlation Between Different Contaminants Across Stations')
plt.tight_layout()
plt.show()

```



Este análisis profundiza en las relaciones entre contaminantes en cada estación:

- Crea una matriz de gráficos de dispersión (pairplot) para cada estación
- Muestra las relaciones entre pares de contaminantes (CO-O3, CO-NO2, O3-NO2)
- Incluye histogramas de la distribución de cada contaminante en la diagonal


Conclusiones destacables: - Se pueden observar relaciones lineales entre los contaminantes CO y NO2 - La relacion con O3 con otros contaminantes es no lineal, pero se concentra en una región distinta

```
[7]: # Scatter plot matrix for different contaminants at the same station
for station in stations:
    station_data = pd.DataFrame()


    for contaminant, daily_avg in daily_avg_by_contaminant.items():
        if station in daily_avg.columns:
            station_data[contaminant] = daily_avg[station]

    if not station_data.empty and len(station_data.columns) > 1:
        sns.pairplot(station_data.dropna())
        plt.suptitle(f'Relationships Between Contaminants at Station_{station}', y=1.02)
        plt.tight_layout()
        plt.show()
```

Relationships Between Contaminants at Station BJU



Relationships Between Contaminants at Station UAX



Relationships Between Contaminants at Station MER

